

Detección de Enfermedades Foliares en Cultivos de Maíz mediante Deep Learning en Dispositivos Móviles

Josías Abner Rivas Fuentes (RF20010)
David Alejandro Deras Cerros (DC19019)
Elmer Edenilson Rosales Molina (RM20001)

Grupo de Trabajo 02
Curso de Especialización en Machine Learning
Universidad de El Salvador

Resumen—El cultivo de maíz constituye una actividad agrícola relevante en El Salvador, donde la identificación oportuna de enfermedades foliares puede contribuir a reducir pérdidas productivas. Este trabajo presenta una aplicación móvil capaz de clasificar tres enfermedades foliares del maíz (como mínimo) y hojas sanas a partir de imágenes, operando completamente offline en dispositivos Android de gama media y baja. La propuesta adopta la metodología CRISP-DM y emplea transferencia de aprendizaje sobre arquitecturas ligeras de visión por computadora. Se establecen como objetivos de desempeño un $Macro F_1 \geq 0,85$ y una alta sensibilidad por clase, junto con restricciones de despliegue orientadas a mantener un modelo liviano y tiempos de inferencia reducidos. El sistema busca apoyar la identificación temprana de enfermedades en campo y servir como base para futuras mejoras mediante la incorporación de datos recolectados en condiciones reales de uso.



1. INTRODUCCIÓN Y METODOLOGÍA (CRISP-DM)

El proyecto se gestiona con el marco **CRISP-DM**, asegurando trazabilidad entre necesidades reales del agricultor, datos, modelado, evaluación y despliegue en campo. Este enfoque iterativo permite ajustar decisiones técnicas con base en evidencia y restricciones de hardware móvil.

2. PUNTOS CLAVE Y RELEVANCIA DEL PROYECTO

Para facilitar la evaluación estratégica y la viabilidad del proyecto, se destacan los siguientes factores y decisiones de diseño:

- **Impacto socioeconómico:** El enfoque está orientado a pequeños productores (82.1 % del sector), para reducir pérdidas que pueden alcanzar hasta el 70 % si no se detectan enfermedades en las primeras dos semanas.
- **Riesgo agronómico:** Se prioriza el *Recall* por clase para minimizar falsos negativos, que son más costosos que falsos positivos en campo.
- **Viabilidad operativa:** La solución funciona sin internet y se optimiza para celulares Android de gama media/baja, con un modelo liviano y latencia baja.
- **Adaptación al entorno real:** El entrenamiento progresa desde imágenes controladas hacia imágenes de campo para mejorar la generalización bajo sombras, iluminación variable y fondos naturales.
- **Mejora continua:** La app puede recolectar nuevas muestras y metadatos con conexión disponible, construyendo un repositorio para futuros reentrenamientos.

3. DEFINICIÓN DEL PROBLEMA

El proyecto aborda una clasificación supervisada multi-clase de etiqueta única con cuatro categorías iniciales: tres enfermedades foliares de alta incidencia (roya común, tizon foliar, mancha gris) y hoja sana. Se evita detección de objetos y clasificación multi-etiqueta para reducir complejidad en el dispositivo móvil y mantener un flujo simple de uso en campo.

4. ADQUISICIÓN DE DATOS Y PARTICIÓN ESTRATIFICADA

El desarrollo del modelo requiere una base representativa y estandarizada. Para ello, se compilará un repositorio de datos curado de un tamaño mínimo de $N = 3,200$ imágenes (sin contar las que se agreguen mediante data augmentation). Las muestras provienen de una combinación balanceada de repositorios públicos indexados y fotografías reales tomadas mediante trabajo de campo.

Se mantiene un balance estricto de clases de aproximadamente $N_c \approx 700$ imágenes por cada una de las cuatro categorías objetivo. A fin de evaluar la capacidad de generalización del modelo frente a datos no observados, la base de datos completa se divide mediante una partición estratificada (*stratified train-validation-test split*) que mantiene el equilibrio original de clases, distribuida en:

- 70 % para el conjunto de entrenamiento ($N_{\text{train}} \approx 2,240$ muestras).

- 15 % para el conjunto de validación interna y sintonía de hiperparámetros ($N_{val} \approx 480$ muestras).
- 15 % para el conjunto de pruebas finales offline ($N_{test} \approx 480$ muestras).

5. ARQUITECTURA DE RED Y ESTRATEGIA DE TRANSFER LEARNING

La arquitectura neuronal de referencia para dispositivos móviles es **MobileNetV3**, la cual optimiza el consumo de recursos mediante bloques de cuello de botella invertidos lineales (*inverted residual bottlenecks*) con conexiones residuales, convoluciones separables en profundidad (*depthwise separable convolutions*), mecanismos de atención de canal *Squeeze-and-Excitation* (SE) y activaciones no lineales *hard-swish*. Se contemplan comparativas sistemáticas de rendimiento con **MobileNetV2** y **EfficientNet B0-B3** para equilibrar la latencia y la precisión.

Para contrarrestar el desajuste de distribución o cambio de covarianza (*covariate shift*) entre las imágenes de laboratorio (dominio de origen $P_S(X)$ con alta nitidez y fondos controlados) y el entorno operativo real de campo (dominio de destino $P_T(X)$ con variaciones de oclusión, iluminación y fondo natural), el entrenamiento se estructura en tres fases:

1. **Preentrenamiento:** Transferencia de pesos base desde el dominio generalista ImageNet ($\theta_{pretrained}$).
2. **Fine-Tuning Controlado:** Ajuste con aumento de datos estocástico (rotaciones, recortes, perturbaciones lumínicas) sobre conjuntos de datos estáticos en entornos de estudio.
3. **Fine-Tuning de Campo:** Ajuste final exclusivo y con una tasa de aprendizaje reducida ($\eta_{field} \ll \eta_{lab}$) sobre imágenes reales capturadas directamente en parcelas locales para fijar la adaptación de dominio.

6. FUNCION DE PERDIDA Y OPTIMIZACION

Se utilizara entropia cruzada categorial con ponderacion por clase para reducir sesgos de muestreo, y el optimizador Adam por su estabilidad en convergencia. Esta combinacion permite priorizar la deteccion de enfermedades menos frecuentes sin penalizar la precision global.

7. CRITERIOS DE ACEPTACION ALGORITMICA

Dado que un falso negativo es mas costoso en campo, se prioriza *Recall* por clase. El criterio de aceptacion establece $Recall \geq 0,85$ para cada patologia y un $Macro F_1 \geq 0,85$, evaluados en un conjunto de prueba independiente y compuesto principalmente por imagenes reales de campo.

8. RESTRICCIONES DE DESPLIEGUE (EDGE AI)

La solución requiere inferencia determinista local con tolerancia cero a latencia de red (Inferencia 100 % Offline), diseñada para ejecutarse en el ecosistema Android mediante una Aplicación Web Progresiva (PWA). El modelo congelado (FP32) se optimiza mediante cuantización estricta de enteros post-entrenamiento (PTQ Int8), reduciendo el rango dinámico de pesos y activaciones a enteros de 8 bits (W_8A_8) para maximizar la velocidad de cómputo en la CPU móvil.

Cuadro 1
Límites Operativos de la Inferencia Local

Métrica de Recurso	Restricción	Método de Validación
Tamaño del Binario .tflite	≤ 20 MB	Inspección de Sistema
Latencia de Inferencia	≤ 300 ms	Telemetría On-Device
Consumo de RAM Volátil	< 200 MB	Android Profiler
Hardware de Referencia	SoC ~Snapdragon 6xx	Terminal de Gama Media/Baja

Debido a la ausencia de aprendizaje local en el dispositivo (*on-device learning*), el ciclo evolutivo del software implementará la recolección pasiva de telemetría de imágenes comprimidas mediante una sincronización asíncrona hacia una API en FastAPI, para construir un repositorio estructurado destinado a fases posteriores de reentrenamiento (el reentrenamiento no forma parte de este trabajo).

9. VALOR OPERATIVO Y ENTREGABLES PARA EL USUARIO FINAL

El sistema de aplicación móvil está diseñado para que el productor agrícola o técnico agrónomo obtenga beneficios directos e inmediatos en el punto de inspección del cultivo:

1. **Diagnóstico Fitosanitario en Tiempo Real:** El usuario obtiene una clasificación automatizada instantánea que identifica de forma específica si la planta padece de alguna enfermedad, o si el tejido foliar se encuentra sano, reduciendo los tiempos de respuesta agrícola.
2. **Autonomía Operativa Fuera de Red:** Gracias a la inferencia 100 % offline, el usuario obtiene la capacidad de diagnosticar sus parcelas en zonas de cultivo aisladas donde no existe cobertura de red móvil ni conexión a internet.
3. **Certidumbre de Diagnóstico:** La aplicación proporciona una métrica de confianza probabilística (p^*) asociada al diagnóstico. Esto permite al usuario evaluar de manera cuantitativa el nivel de fiabilidad de la clasificación antes de iniciar intervenciones.
4. **Directrices de Mitigación Agronómica:** Ante cualquier detección positiva de enfermedad, el usuario obtiene en pantalla recomendaciones agronómicas y planes de acción pre-cargados para contener y tratar la patología foliar identificada.

10. DOCUMENTACION DEL PROYECTO

Se mantendra una web de seguimiento que funcione como documentacion viva e historial de trabajo mediante Git. En ella ya se pueden consultar los primeros analisis de los datasets evaluados a la fecha (31-05-2026): *DoctorMaiz* (<https://doctor-maiz.deras.dev/es/>).

El repositorio oficial de documentacion, notebooks, scripts y materiales del proyecto se encuentra en GitHub: *daiv05/corn-leaf-desease-project* (<https://github.com/daiv05/corn-leaf-desease-project>).

11. FECHAS CLAVE

- 22 de junio al 5 de julio: Desarrollo del proyecto en etapa 1.
- 31 de agosto al 12 de septiembre: Desarrollo del proyecto en etapa 2.
- 8 al 21 de noviembre: Trabajo final y presentacion del modelo de Machine Learning.

12. CIERRE

La propuesta traduce una necesidad critica del sector maicero en una herramienta util y viable para campo: diagnostico temprano, uso sin internet y metas de calidad verificables. El enfoque metodologico, la adaptacion a datos reales y las restricciones de despliegue permiten ofrecer una solucion útil, viable y con potencial de mejora continua mediante recoleccion controlada de datos locales.